

Проведем нагрузочное тестирование нашего потокобезопасного, асинхронного сервера с помощью *wrk* в несколько соединений после переключения внутреннего взаимодействия узлов на асинхронный *java.net.http.HttpClient*. Проанализируем результаты профилирования под нагрузкой с помощью *async-profiler*. Профилирование будем проводить трех типов:

- *CPU profiling*;
- *Allocation profiling*;
- *Lock profiling*.

Сравним результаты с предыдущей версией сервера.

1 Put

Проведем нагрузку на сервер запросами на вставку данных:

```
$ wrk -c 128 -d1m -R1000 -s ./wrk/put.lua -L \
> http://localhost:8080

      Thread Stats   Avg      Stdev     Max    +/-  Stdev
      Latency       2.53ms    2.29ms   32.80ms   94.90%
      Req/Sec      527.38    187.54    2.44k    80.24%
Latency Distribution (HdrHistogram - Recorded Latency)
50.000%    2.08ms
75.000%    2.47ms
90.000%    3.02ms
99.000%   14.57ms
99.900%   23.97ms
99.990%   30.32ms
99.999%   32.83ms
100.000%   32.83ms

#[Mean      =          2.529, StdDeviation    =          2.293]
#[Max       =          32.800, Total count     =         49676]
#[Buckets   =           27, SubBuckets       =         2048]
-----
 59906 requests in 1.00m, 3.83MB read
Requests/sec:    998.42
Transfer/sec:    65.33KB
```

Сравним HdrHistogram с диаграммой, получившейся на предыдущей версии сервера:

```
$ wrk -c 128 -d1m -R1000 -s ./wrk/put.lua -L \
> http://localhost:8080

Thread calibration: mean lat.: 1.866ms, rate sampling interval: 10ms
Thread calibration: mean lat.: 5.077ms, rate sampling interval: 14ms
      Thread Stats   Avg      Stdev     Max    +/-  Stdev
      Latency       3.39ms    2.36ms   25.41ms   82.07%
      Req/Sec      522.15    839.14    4.92k    94.32%
```

```

Latency Distribution (HdrHistogram - Recorded Latency)
50.000%    2.57ms
75.000%    4.80ms
90.000%    6.11ms
99.000%   11.73ms
99.900%   20.33ms
99.990%   22.38ms
99.999%   25.42ms
100.000%   25.42ms

#[Mean      =      3.387, StdDeviation      =      2.357]
#[Max       =      25.408, Total count      =      49670]
#[Buckets   =      27, SubBuckets          =      2048]
-----
59458 requests in 1.00m, 3.80MB read
Requests/sec: 990.80
Transfer/sec: 64.83KB

```

Можно увидеть, что на новой версии сервера увеличились как малые, так и высокие перцентили, но незначительно, например, 99 перцентиль увеличился на 7 миллисекунд. Стоит отметить, что на новой версии наблюдается прирост пропускной способности.

Рассмотрим результаты профилирования трех режимов: *cpu* (рис. 1) , *alloc* (рис. 2) и *lock* (рис. 3).

На рис. 1 видно, что больше всего времени заняла работа воркеров: вызовы методов у *CompletableFuture*, работа с сетью. Так же видна работа *ForkJoinPool*, поскольку он обрабатывал задачи, которые были прокинуты в *CompletableFuture*. На селекторах, как и раньше, происходит только обработка запросов.

Что касается аллокации памяти (рис. 2), то большая ее часть выделяется для работы с сетью и с *CompletableFuture*.

В режиме *lock* (рис. 3) видно, что блокировки происходили при работе с *CompletableFuture*, поскольку это инструмент межпоточкового взаимодействия, также блокировки возникали с добавленным *HttpClient*, например, при обработке запросов и ответов. Блокировка, связанная с записью в хранилище, заняла малую часть времени (1%).




Рис. 1




Рис. 2

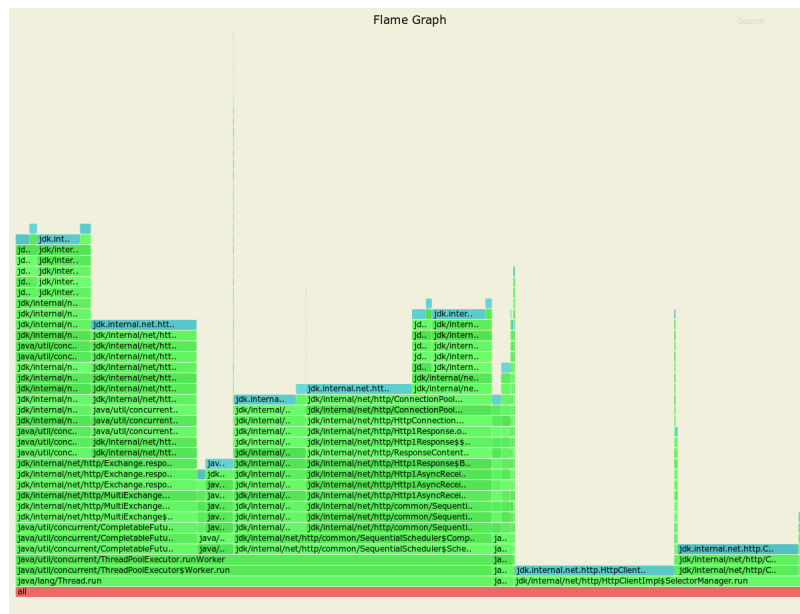


Рис. 3

2 Get

Проведем нагрузку на сервер запросами на получение данных (хранилище заполнено на 100M):

```
$ wrk -c 128 -d1m -R1000 -s ./wrk/get.lua -L \
> http://localhost:8080
```

Thread Stats	Avg	Stdev	Max	+/-	Stdev
Latency	18.65ms	14.74ms	71.68ms	51.47%	
Req/Sec	504.02	229.83	1.15k	69.61%	

Latency Distribution (HdrHistogram - Recorded Latency)

50.000%	20.29ms
75.000%	29.02ms
90.000%	38.56ms
99.000%	54.14ms
99.900%	64.38ms
99.990%	68.74ms
99.999%	71.74ms
100.000%	71.74ms

```
# [Mean      =      18.653, StdDeviation    =      14.742]
# [Max      =      71.680, Total count     =      49670]
# [Buckets  =      27, SubBuckets        =      2048]
```

```
59458 requests in 1.00m, 4.10MB read
Requests/sec: 990.64
Transfer/sec: 69.93KB
```

Сравним HdrHistogram с диаграммой, получившейся на прошлой версии сервера при той же нагрузке:

```
$ wrk -c 128 -d1m -R1000 -s ./wrk/get.lua -L \
> http://localhost:8080

Thread Stats   Avg      Stdev     Max    +/-  Stdev
  Latency    4.81ms    4.03ms   31.98ms   81.00%
  Req/Sec    521.90    509.35    2.67k    73.35%
  Latency Distribution (HdrHistogram - Recorded Latency)
50.000%    2.74ms
75.000%    7.48ms
90.000%   10.38ms
99.000%   18.21ms
99.900%   25.17ms
99.990%   29.04ms
99.999%   32.00ms
100.000%   32.00ms

#[Mean      =      4.811, StdDeviation    =      4.027]
#[Max       =     31.984, Total count     =     49670]
#[Buckets   =      27, SubBuckets        =     2048]
-----
 59462 requests in 1.00m, 4.10MB read
Requests/sec:    990.82
Transfer/sec:     69.95KB
```

Можно увидеть, что значительно увеличило значения на всех перцентилях, а пропускная способность не изменилась.

Рассмотрим результаты профилирования трех режимов: *cpu* (рис. 4) , *alloc* (рис. 5) и *lock* (рис. 6).

На рис. 4 видно, что больше всего времени заняла работа воркеров: вызовы методов у *CompletableFuture*, работа с сетью. Так же видна работа *ForkJoinPool*, обрабатывающий задачи *CompletableFuture*. Большую часть времени в *ForkJoinPool* заняло получение итератора у *LSMDao*.

Что касается аллокации памяти (рис. 5), то большая ее часть в *ForkJoinPool* была выделена объектам класса *DirectByteBuffer*, которые создавались при вызове метода *SSTable.iterator*. Остальная аллокация памяти происходила при работе с сетью и с *CompletableFuture*.

На рис. 6 видно, что блокировки были также связаны с межпоточковым взаимодействием *CompletableFuture* и с обработкой запросов/ответов у *HttpClient*.




Рис. 4

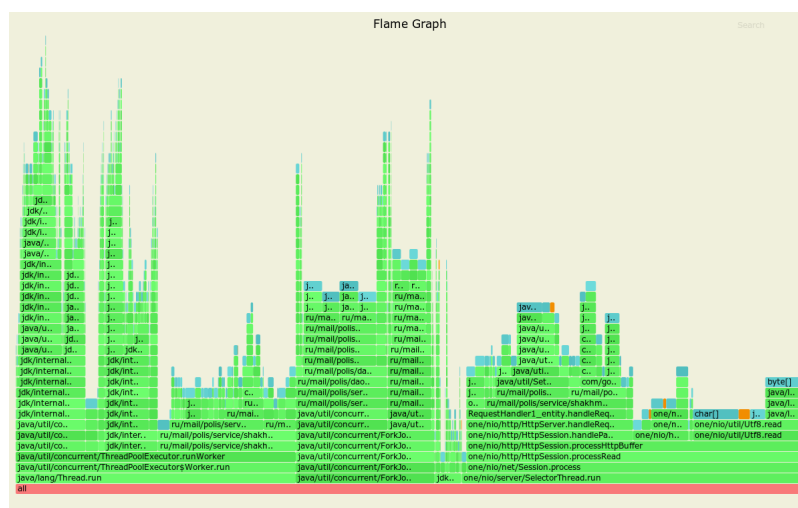


Рис. 5

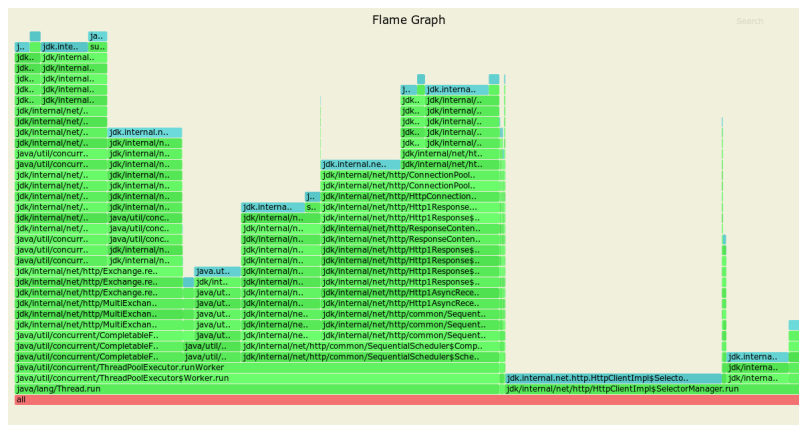


Рис. 6

3 Delete

Проведем нагрузку на сервер запросами на удаление данных:

```
$ wrk -c 128 -d1m -R1000 -s ./wrk/delete.lua -L \
> http://localhost:8080
```

Thread Stats	Avg	Stdev	Max	+/-	Stdev
Latency	1.93ms	1.75ms	57.82ms	97.87%	
Req/Sec	527.63	146.88	3.40k	80.55%	

Latency Distribution (HdrHistogram - Recorded Latency)

50.000%	1.74ms
75.000%	2.10ms
90.000%	2.51ms
99.000%	7.13ms
99.900%	26.91ms
99.990%	54.27ms
99.999%	57.85ms
100.000%	57.85ms

```
# [Mean      =      1.929, StdDeviation      =      1.749]
# [Max       =      57.824, Total count      =      49676]
# [Buckets   =      27, SubBuckets          =      2048]
```

```
59906 requests in 1.00m, 3.88MB read
Requests/sec: 998.41
Transfer/sec: 66.30KB
```

Сравним HdrHistogram с диаграммой, получившейся на прошлой версии сервера:

```
$ wrk -c 128 -d1m -R1000 -s ./wrk/delete.lua \
> http://localhost:8080
```

Thread Stats	Avg	Stdev	Max	+/-	Stdev
Latency	3.04ms	2.17ms	37.86ms	85.17%	




Рис. 8

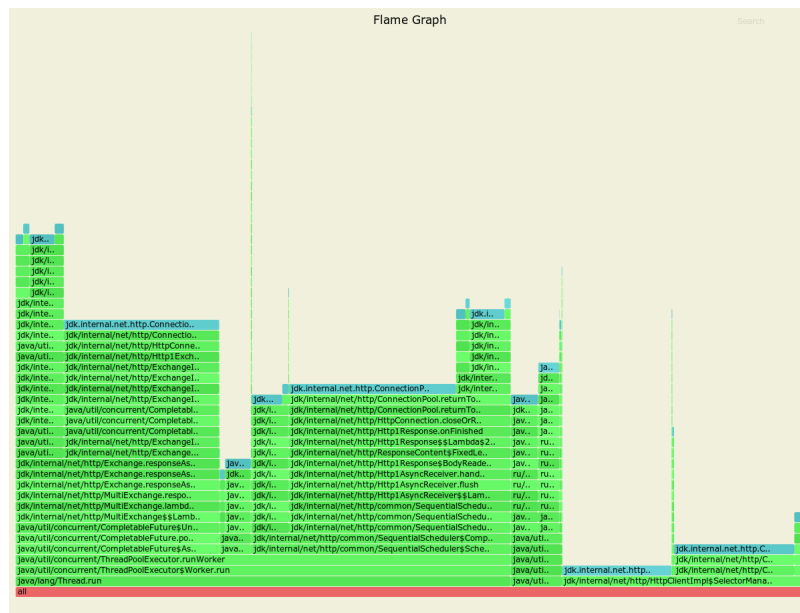


Рис. 9